



Введение в машинное обучение

Ермакова Анна, аналитик

План лекции

- 1 | Что такое машинное обучение, его приложения
- 2 | Общепринятые обозначения и используемые термины
- 3 | Виды задач обучения с учителем
- 4 | Модель
- 5 | Метрики качества модели


1



Что такое машинное обучение, его приложения

Что такое машинное обучение, его приложения

- › **Машинное обучение** — это наука, изучающая алгоритмы, автоматически улучшающиеся благодаря опыту.



Что такое машинное обучение, его приложения

› Приложения машинного обучения

- Рекомендательные системы

<https://research.netflix.com/research-area/machine-learning>

- Поиск

<https://habr.com/ru/company/yandex/blog/174213/>

- Умные ассистенты

<https://habr.com/ru/company/yandex/blog/593681/>

- Погода

<https://habr.com/ru/company/yandex/blog/565238/>

- Перевод текста

- Диагностика болезней



Что такое машинное обучение, его приложения

› Приложения компьютерного зрения

- Системы видеонаблюдения

распознавание лиц, номеров автомобилей

- Робототехника

распознавание объектов, знаков дорожного движения


- Диагностика болезней

анализ медицинских изображений

- Обработка фотографий

- Сельское хозяйство

распознавание веса животных, их здоровья



Что такое машинное обучение, его приложения

- › Chihuahua or Muffin – классификация изображений сложнее, чем кажется



2



Общепринятые обозначения и используемые термины

Общепринятые обозначения и используемые термины

› Задача обучения по набору объектов или примеров (sample)

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский	5	TRUE
Аня	17	4	5	Коричневый	Русский	4	TRUE
Емеля	25	5	5	Голубой	Английский	5	TRUE
Настя	27	3	4	Зелёный	Русский	5	TRUE
Миша	23	5	4	Неизвестно	Испанский	2	FALSE

Восстановление эмпирических зависимостей в данных.

Общепринятые обозначения и используемые термины

› Наблюдение (observation)

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский	5	TRUE
Аня	17	4	5	Коричневый	Русский	4	TRUE
Емеля	25	5	5	Голубой	Английский	5	TRUE
Настя	27	3	4	Зелёный	Русский	5	TRUE
Миша	23	5	4	Неизвестно	Испанский	2	FALSE

Описание **объекта**.

Общепринятые обозначения и используемые термины

› Выборка (dataset)

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский	5	TRUE
Аня	17	4	5	Коричневый	Русский	4	TRUE
Емеля	25	5	5	Голубой	Английский	5	TRUE
Настя	27	3	4	Зелёный	Русский	5	TRUE
Миша	23	5	4	Неизвестно	Испанский	2	FALSE

Набор наблюдений.

Общепринятые обозначения и используемые термины

› Признаковое описание (features)

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский	5	TRUE
Аня	17	4	5	Коричневый	Русский	4	TRUE
Емеля	25	5	5	Голубой	Английский	5	TRUE
Настя	27	3	4	Зелёный	Русский	5	TRUE
Миша	23	5	4	Неизвестно	Испанский	2	FALSE

Фиксированный набор признаков, измеренных для каждого объекта.
Могут быть **числовыми** или **категориальными**.

Общепринятые обозначения и используемые термины

› Признаковое описание (features)

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский	5	TRUE
Аня	17	4	5	Коричневый	Русский	4	TRUE
Емеля	5	5	5	Голубой	Английский	5	TRUE
Настя	27	3	4	Зелёный	Русский	5	TRUE
Миша	23	5	4	Неизвестно	Испанский	2	FALSE

Фиксированный набор признаков, измеренных для каждого объекта.

Могут быть **числовыми** или **категориальными**.

Общепринятые обозначения и используемые термины

› Признаковое описание (features)

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский	5	TRUE
Аня	17	4	5	Коричневый	Русский	4	TRUE
Емеля	25	5	5	Голубой	Английский	5	TRUE
Настя	27	3	4	Зелёный	Русский	5	TRUE
Миша	23	5	4	Неизвестно	Испанский	2	FALSE

Фиксированный набор признаков, измеренных для каждого объекта.

Могут быть **числовыми** или **категориальными**.

Общепринятые обозначения и используемые термины

› Признаковое описание (features)

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский	5	TRUE
Аня	17	4	5	Коричневый	Русский	4	TRUE
Емеля	25	5	5	Голубой	Английский	5	TRUE
Настя	27	3	4	Зелёный	Русский	5	TRUE
Миша	23	5	4	Неизвестно	Испанский	2	FALSE

Фиксированный набор признаков, измеренных для каждого объекта.
Могут быть **числовыми** или **категориальными**.

Общепринятые обозначения и используемые термины

› Обучение с учителем

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский	5	TRUE
Аня	17	4	5	Коричневый	Русский	4	TRUE
Емеля	25	5	5	Голубой	Английский	5	TRUE
Настя	27	3	4	Зелёный	Русский	5	TRUE
Миша	23	5	4	Неизвестно	Испанский	2	FALSE

Правильные ответы для каждого объекта обучающей выборки заранее известны.

Общепринятые обозначения и используемые термины

› Обучение с учителем

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский	5	TRUE
Аня	17	4	5	Коричневый	Русский	4	TRUE
Емеля	25	5	5	Голубой	Английский	5	TRUE
Настя	27	3	4	Зелёный	Русский	5	TRUE
Миша	23	5	4	Неизвестно	Испанский	2	FALSE

В задаче **обучения с учителем** наблюдение состоит из **объекта (sample)** и **ответа (target)**.

Общепринятые обозначения и используемые термины

› Обучение без учителя

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский		
Аня	17	4	5	Коричневый	Русский		
Емеля	25	5	5	Голубой	Английский		
Настя	27	3	4	Зелёный	Русский		
Миша	23	5	4	Неизвестно	Испанский		

В задаче **обучения без учителем** известны только объекты, а ответы неизвестны или вообще не существуют.

3



Виды задач обучения с учителем

Виды задач обучения с учителем

› Задача регрессии

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский	5	TRUE
Аня	17	4	5	Коричневый	Русский	4	TRUE
Емеля	25	5	5	Голубой	Английский	5	TRUE
Настя	27	3	4	Зелёный	Русский	5	TRUE
Миша	23	5	4	Неизвестно	Испанский	2	FALSE

Ответом является число.

Виды задач обучения с учителем

› Задача бинарной классификации

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский	5	TRUE
Аня	17	4	5	Коричневый	Русский	4	TRUE
Емеля	25	5	5	Голубой	Английский	5	TRUE
Настя	27	3	4	Зелёный	Русский	5	TRUE
Миша	23	5	4	Неизвестно	Испанский	2	FALSE

Ответ – бинарный, «да» или «нет».

Виды задач обучения с учителем

› Задача многоклассовой классификации

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский	5	TRUE
Аня	17	4	5	Коричневый	Русский	4	TRUE
Емеля	25	5	5	Голубой	Английский	5	TRUE
Настя	27	3	4	Зелёный	Русский	5	TRUE
Миша	23	5	4	Неизвестно	Испанский	2	FALSE

Ответ – принадлежность к некоторому классу.

Виды задач обучения с учителем

› Другие виды задач обучения с учителем

- Многоклассовая классификация с переспекающимися классами

Ответ – набор меток принадлежности к подходящим классам

- Ранжирование

Ответ – номер объекта в отранжированном списке

4



Модель

Модель

› Модель – алгоритм, который приближает неизвестную зависимость

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский	5	TRUE
Аня	17	4	5	Коричневый	Русский	4	TRUE
Емеля	25	5	5	Голубой	Английский	5	TRUE
Настя	27	3	4	Зелёный	Русский	5	TRUE
Миша	23	5	4	Неизвестно	Испанский	2	FALSE

Модель

› Параметрическая модель – комбинация фичей

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский	5	TRUE
Аня	17	4	5	Коричневый	Русский	4	TRUE
Емеля	25	5	5	Голубой	Английский	5	TRUE
Настя	27	3	4	Зелёный	Русский	5	TRUE
Миша	23	5	4	Неизвестно	Испанский	2	FALSE

$$\widehat{\text{mark_ML}_{avg}} = \frac{1}{2} \text{mark}_{Statistics} + \frac{1}{2} \text{mark}_{Python}$$

Модель

› Константная или случайная модель

Имя	Возраст	Статистика (оценка)	Python (оценка)	Цвет глаз	Язык	ML (оценка)	Зачтено
Иван	22	5	4	Голубой	Английский	5	TRUE
Аня	17	4	5	Коричневый	Русский	4	TRUE
Емеля	25	5	5	Голубой	Английский	5	TRUE
Настя	27	3	4	Зелёный	Русский	5	TRUE
Миша	23	5	4	Неизвестно	Испанский	2	FALSE

$$\text{mark_}\widehat{ML}_{rand} = \text{randint}(1, 5)$$

5



Метрики качества модели

Метрики качества модели

› Виды метрик глобально

- Бизнес-метрики

Про доход

- Онлайн (online) метрики

характеристики системы, влияющие на бизнес метрики

- Офлайн (offline) метрики

могут быть измерены заранее по историческим данным



Метрики качества модели

› Метрика (metric)

Имя	$y =$ ML (оценка)	$\widehat{y_{avg}} =$ $mark_ML_{avg}$	$ \widehat{y_{avg}} - y $	$\widehat{y_{rand}} =$ $mark_ML_{rand}$	$ \widehat{y_{rand}} - y $
Иван	5	4.5	0.5	1	4
Аня	4	4.5	0.5	5	1
Емеля	5	5	0	3	2
Настя	5	3.5	1.5	4	1
Миша	2	4.5	2.5	2	0

Функция, позволяющая оценить качество модели a на некоторой выборке

$$X.err_{avg} = \frac{1}{N} \sum_{i=0}^N |\widehat{y_{avg}} - y| = 1$$

$$err_{rand} = \frac{1}{N} \sum_{i=0}^N |\widehat{y_{rand}} - y| = 1.75$$

Метрики качества модели

› Метрики регрессии

- Средняя квадратичная ошибка (Mean Squared Error, MSE)

$$MSE = \frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2$$

- Средняя абсолютная ошибка (Mean Absolute Error, MAE)

$$MAE = \frac{1}{N} \sum_{i=1}^N |\hat{y}_i - y_i|$$

- Корень из средней квадратичной ошибки (Root Mean Squared Error, RMSE)

$$RMSE = \sqrt{\frac{1}{N} \sum_{i=1}^N (\hat{y}_i - y_i)^2}$$

Метрики качества модели

› Метрики бинарной классификации

Аккуратность (Accuracy) – доля объектов, для которых мы верно предсказали класс

$$Accuracy = \frac{1}{N} \sum_{i=1}^N I[\hat{y}_i = y_i]$$

Проблемы Accuracy:

- Не учитывает дисбаланс классов
- Не учитывает цену ошибки на объектах разных классов

Метрики качества модели

› Ассигасу в задаче с неравными классами

Имеется 100 настоящих штрихкодов Лавки и 10 фейковых

Обученный классификатор:

- 90 классификатор определил верно -> TP = 90, FN = 10
- 5 классификатор определил верно -> TN = 5, FP = 5


$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} = \frac{90+5}{90+5+5+10} = 86,4$$

Константная модель:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} = \frac{0 + 100}{0 + 100 + 0 + 10} = 90,9$$

Метрики качества модели

› Матрица ошибок (confusion matrix)



Метрики качества модели

› Матрица ошибок (confusion matrix)

Correct/incorrect prediction?

True	False
False	True

Meaning of true and false

Positive/negative class prediction?

+	-
+	-

Meaning of positive and negative

Метрики качества модели

› Метрики качества бинарной классификация в терминах матрицы ошибок

– Аккуратность (Accuracy)

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$$

– Точность (Precision)

$$Precision = \frac{TP}{TP+FP}$$

– Полнота (Recall)

$$Recall = \frac{TP}{TP+FN}$$

– F-мера

$$F = \frac{Precision * Recall}{\beta^2 Precision + Recall} * (1 + \beta^2)$$

Метрики качества модели

› Метрики качества бинарной классификация в терминах матрицы ошибок

– Аккуратность (Accuracy)

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN}$$

– Точность (Precision)


$$Precision = \frac{TP}{TP+FP}$$

– Полнота (Recall)

$$Recall = \frac{TP}{TP+FN}$$

– F-мера

$$F = \frac{Precision * Recall}{\beta^2 Precision + Recall} * (1 + \beta^2)$$



Метрики качества модели

› Бинарная классификация - вероятности классов

Часто модель выдает не ответ 0/1, а вероятность принадлежности положительному классу.

Считают, что объект принадлежит положительному классу, если вероятность выше некоторого порога.

Как выбрать этот порог?

- уменьшаем порог → находим (правильно предсказываем) все большее число положительных объектов, НО также и неправильно предсказываем положительную метку на все большем числе отрицательных объектов

Метрики качества модели

› Метрики качества бинарной классификации – ROC / AUC

– True Positive Rate (TPR)

$$TRP = \frac{TP}{TP+FN}$$

– False Positive Rate (FPR)

$$FPR = \frac{FP}{TN+FP}$$

– ROC - кривая в осях TPR/FPR


– AUC - площадь под кривой ROC

Метрики качества модели

› Метрики качества бинарной классификации – ROC / AUC

TPR, FPR растут при уменьшении порога

По [этой ссылке](#) интерактивный график, который поможет вам понять поведение ROC-кривой



Метрики качества модели

› Метрики качества многоклассовой классификации

К классов. Задача – разделить класс i от остальных классов ($i = 1, \dots, K$).

Шаг 1 - Считаем матрицу ошибок для каждого класса i , считая i – положительным классом, а все остальные – отрицательным.

Шаг 2 – усредняем, чтобы получить метрики. Есть два способа:

- **Микроусреднение.** Усредняем элементы матрицы ошибок (TP, FP, TN, FN) между бинарными классификаторами, например $TP = \frac{1}{K} \sum_{i=1}^K TP_i$. Затем по одной усреднённой матрице ошибок считаем Precision, Recall, F-меру.
- **Макроусреднение.** Считаем Precision, Recall для каждого классификатора отдельно, а потом усредняем.

Метрики качества модели

- › Какие еще могут быть требования к модели?
- Возможность работать в реальном времени
- Компактность
- Интерпретируемость
- Отсутствие дискриминаций в модели